Actividad 5

Materia:	*Gestión de Proyectos de Inteligencia Artificial*
Actividad:	*Actividad 4*
Alumno(a):	*Paola Quinto Martínez*
Matrícula:	*03039650*
Docente:	*Luis Ariel Vázquez Piña*
Fecha de entrega:	*18 Octubre 2026*

Declaración de Uso de Inteligencia Artificial

El alumno debe indicar de manera honesta si utilizó herramientas de Inteligencia Artificial (IA) para el desarrollo de esta actividad. Completa la siguiente tabla:

Herramienta de IA utilizada	¿La usaste?	Propósito / Descripción de uso
ChatGPT / OpenAI	■ Sí ☐ No	Como apoyo para organizar la metodología del proyecto, comprender conceptos relacionados con la clasificación de sentimientos, estructurar el reporte técnico. También se utilizó como apoyo para resolver dudas durante el desarrollo del notebook.
Claude (Anthropic)	☐ Sí ■ No	
Gemini (Google)	☐ Sí ■ No	
Copilot (Microsoft)	☐ Sí ■ No	
Otra (especifica): Codex	■ Sí ☐ No	Apoyo en el entorno de desarrollo para revisar y modificar archivos del proyecto, ejecutar pruebas, preparar documentación y apoyar la organización del repositorio en GitHub.

Actividad 4.

Resumen ejecutivo

En este trabajo se analizaron 14,640 comentarios en inglés sobre aerolíneas y se compararon dos modelos para clasificar su sentimiento: Regresión Logística y Random Forest. Se utilizó TF-IDF para representar los textos y se registraron cuatro ejecuciones en MLflow. Además de la partición estratificada habitual, se revisó un escenario agrupado por texto idéntico para observar el efecto de las repeticiones. Se presentan ambos escenarios por separado, porque corresponden a protocolos distintos.

Objetivo y datos

El objetivo fue clasificar cada comentario como negative, neutral o positive a partir del texto (text), usando airline_sentiment como etiqueta objetivo. Para ello se utilizó el conjunto Twitter US Airline Sentiment, disponible en Kaggle: https://www.kaggle.com/datasets/crowdflower/twitter-airline-sentiment/data. La página atribuye la fuente original a Crowdflower's Data for Everyone library, acredita a Figure Eight y un colaborador, y muestra licencia CC BY-NC-SA 4.0 (consulta registrada: 17-10-2026). No existe registro local de descarga ni checksum del editor; la procedencia byte a byte del CSV no puede autenticarse.

El archivo original contiene 14,640 filas y 15 columnas. Para el modelado se conservó únicamente el texto y la etiqueta, se eliminaron los espacios y se normalizaron las etiquetas a minúsculas. En las comprobaciones realizadas no fue necesario excluir filas por texto vacío o por etiquetas inválidas. Se mantuvieron las repeticiones de texto y etiqueta para poder revisar su posible efecto en la evaluación.

Diccionario de variables

Variable	Descripción / uso
tweet_id	Identificador del tuit; no se utiliza en el modelo.
airline_sentiment	Etiqueta objetivo: negative, neutral o positive.
airline_sentiment_confidence	Confianza de la anotación; excluida del modelo.
negativereason	Motivo anotado para sentimiento negativo; excluido.
negativereason_confidence	Confianza del motivo negativo; excluida.
airline	Aerolínea mencionada; excluida del modelo.
airline_sentiment_gold	Etiqueta suplementaria de referencia; excluida.
name	Nombre de cuenta; dato potencialmente identificable, excluido.
negativereason_gold	Motivo suplementario de referencia; excluido.
retweet_count	Conteo de retuits; excluido.
text	Texto del comentario; única entrada del clasificador.
tweet_coord	Coordenadas declaradas; excluidas.
tweet_created	Fecha del tuit; excluida.
tweet_location	Ubicación declarada; excluida.
user_timezone	Zona horaria declarada; excluida.

Exploración y calidad de los datos

Al revisar la calidad de los datos, se encontraron valores ausentes en campos que no se utilizaron para entrenar los modelos: negativereason (5462), negativereason_confidence (4118), airline_sentiment_gold (14600), negativereason_gold (14608), tweet_coord (13621), tweet_location (4733) y user_timezone

(4820). En las columnas usadas quedaron 0 nulos/vacíos en text y 0 en airline_sentiment. Se registraron 36 filas completas duplicadas en el origen y 188 repeticiones texto-etiqueta; no se eliminaron.

Distribución de clases

Etiqueta	Registros	Porcentaje
negative	9178	62.69%
neutral	3099	21.17%
positive	2363	16.14%

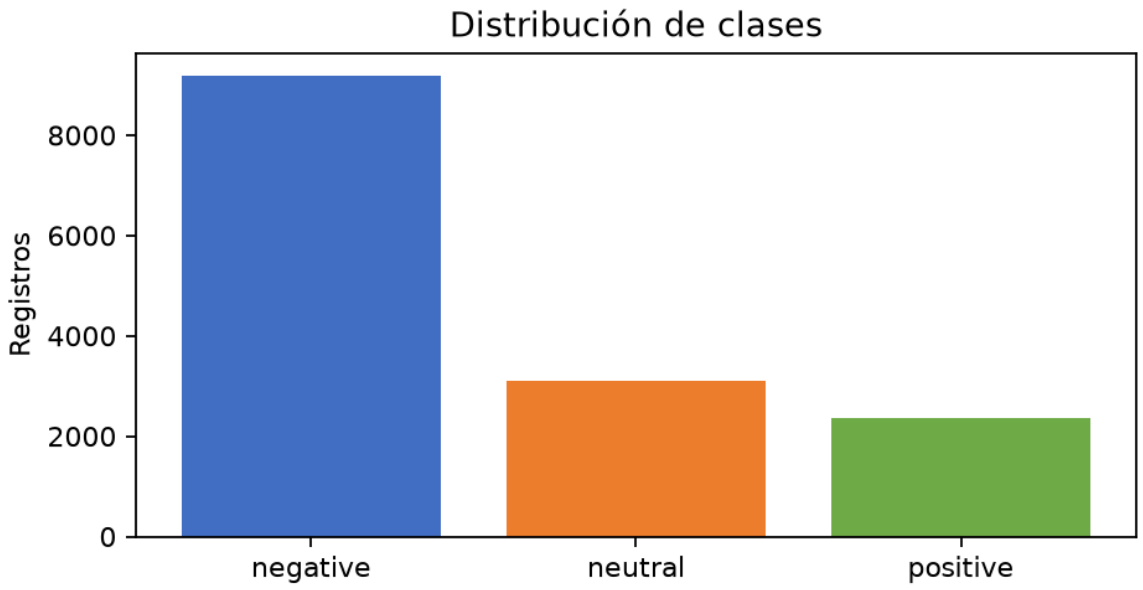


Figura. Distribución de las clases en el dataset limpio.

Artefacto	Filas	SHA-256
CSV de origen local	14640	ea94b23f41892b290dec3330bb8cf9cb6b8bc669eaae5f3a84c40f7b0de8f15e
CSV limpio	14640	82539f706fdafc80f93dec7ae1cfc2310c179952f41548ed5c3ddf36effd67dd

Método y control de evaluación

Para la evaluación original se dividieron los datos de forma estratificada: 80% para entrenamiento y 20% para prueba, con semilla 42. Esto dejó 11,712 registros para entrenar y 2,928 para probar. Se utilizó GridSearchCV con cinco folds y F1 macro como criterio de selección. TF-IDF quedó dentro del pipeline para que se ajustara con los datos de entrenamiento de cada fold, sin utilizar el conjunto de prueba para elegir hiperparámetros.

Al revisar la partición original, se encontraron 71 textos únicos compartidos entre entrenamiento y prueba: 60 con etiqueta consistente en esos conjuntos y 11 con etiquetas distintas. En todo el dataset existen 25 grupos de texto con etiquetas conflictivas. Como evaluación adicional se usó StratifiedGroupKFold (5 folds, semilla 42), reservando el primer fold para prueba y agrupando también la

validación interna. En este protocolo no hubo solapamiento de textos idénticos entre entrenamiento y prueba.

Modelos y búsqueda de hiperparámetros

Se compararon dos enfoques. Regresión Logística es un modelo lineal que trabaja con los vectores dispersos de TF-IDF. Random Forest combina varios árboles de decisión y, en este experimento, utilizó una representación TF-IDF con el vocabulario limitado. La comparación me permitió revisar cómo se comportaron ambos modelos con los mismos datos y criterios de evaluación.

Protocolo	Modelo	Mejores parámetros	F1 macro CV	Búsqueda (tiempo)
Original	logistic_regression	{"classifier__C": 3.0, "tfidf__ngram_range": [1, 2]}	0.7438 ± 0.0099	22.284 s
Original	random_forest	{"classifier__max_depth": 30, "classifier__max_features": "sqrt", "classifier__min_samples_leaf": 3, "classifier__n_estimators": 60, "tfidf__max_features": 10000}	0.6879 ± 0.0061	18.915 s
Agrupada	logistic_regression	{"classifier__C": 1.0, "tfidf__ngram_range": [1, 2]}	0.7434 ± 0.0079	27.620 s
Agrupada	random_forest	{"classifier__max_depth": 30, "classifier__max_features": "sqrt", "classifier__min_samples_leaf": 3, "classifier__n_estimators": 60, "tfidf__max_features": 10000}	0.6820 ± 0.0169	22.278 s

La búsqueda comparó cuatro candidatos por modelo y escenario. En el protocolo original el criterio de selección fue F1 macro. Las métricas de prueba se calcularon después de seleccionar los parámetros; no se usaron para ajustarlos. Los tiempos corresponden a GridSearchCV registrado en los artefactos de cada escenario.

Resultados

Escenario	Modelo	Accuracy	Prec. macro	Recall macro	F1 macro	F1 ponderado	ROC-AUC OVR	F1 CV media ± DE
Original estratificada	Regresión Logística	0.7982	0.7444	0.7504	0.7457	0.8013	0.9110	0.7438 ± 0.0099
Original estratificada	Random Forest	0.7278	0.6606	0.6742	0.6658	0.7330	0.8640	0.6879 ± 0.0061
Agrupada por texto	Regresión Logística	0.7927	0.7350	0.7544	0.7437	0.7962	0.9102	0.7434 ± 0.0079
Agrupada por texto	Random Forest	0.7452	0.6738	0.6842	0.6787	0.7474	0.8696	0.6820 ± 0.0169

Las métricas de prueba y las matrices/reportes proceden de los artefactos validados.La selección se interpreta descriptivamente: no se realizó una prueba de significancia estadística y se usó una sola semilla.

Reporte por clase — Original

Modelo	Clase	Precisión	Recall	F1	Soporte
Regresión Logística	negative	0.894	0.858	0.875	1835
Regresión Logística	neutral	0.604	0.706	0.651	620
Regresión Logística	positive	0.735	0.687	0.710	473
Random Forest	negative	0.850	0.797	0.822	1835
Random Forest	neutral	0.512	0.606	0.555	620
Random Forest	positive	0.621	0.619	0.620	473

Reporte por clase — Agrupado

Modelo	Clase	Precisión	Recall	F1	Soporte
Regresión Logística	negative	0.892	0.844	0.867	1836
Regresión Logística	neutral	0.607	0.684	0.643	620
Regresión Logística	positive	0.707	0.735	0.721	472
Random Forest	negative	0.851	0.827	0.839	1836
Random Forest	neutral	0.550	0.577	0.563	620
Random Forest	positive	0.621	0.648	0.634	472

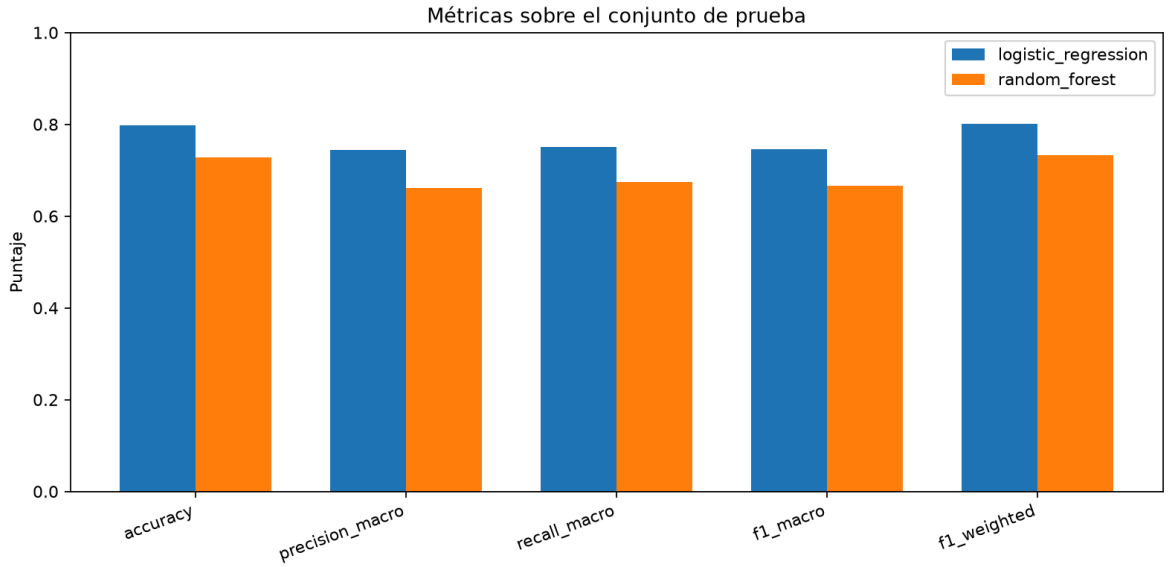


Figura 1. Comparación original de modelos.

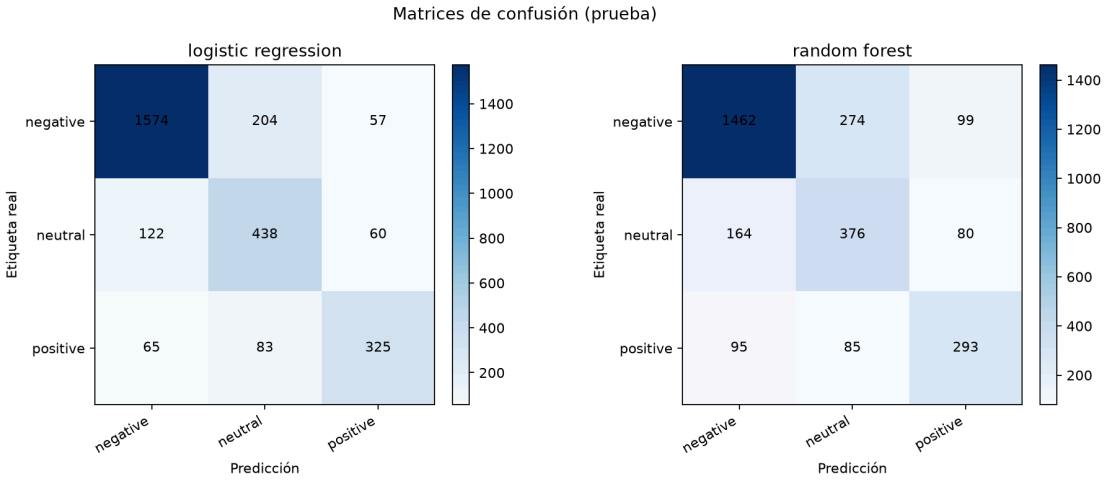


Figura 2. Matrices de confusión del escenario original.

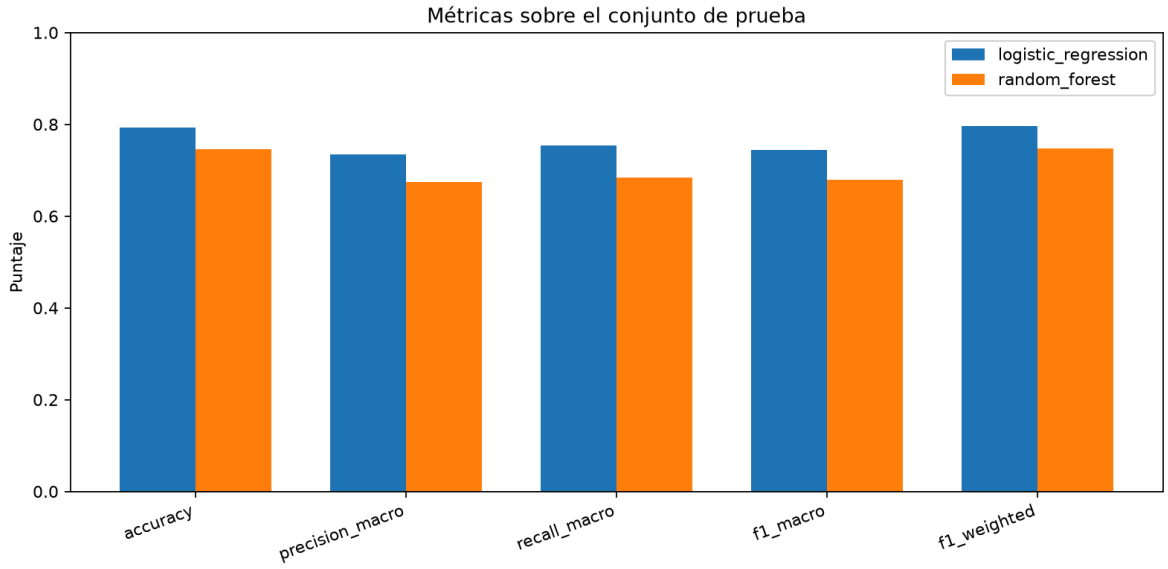


Figura 3. Comparación del escenario agrupado.

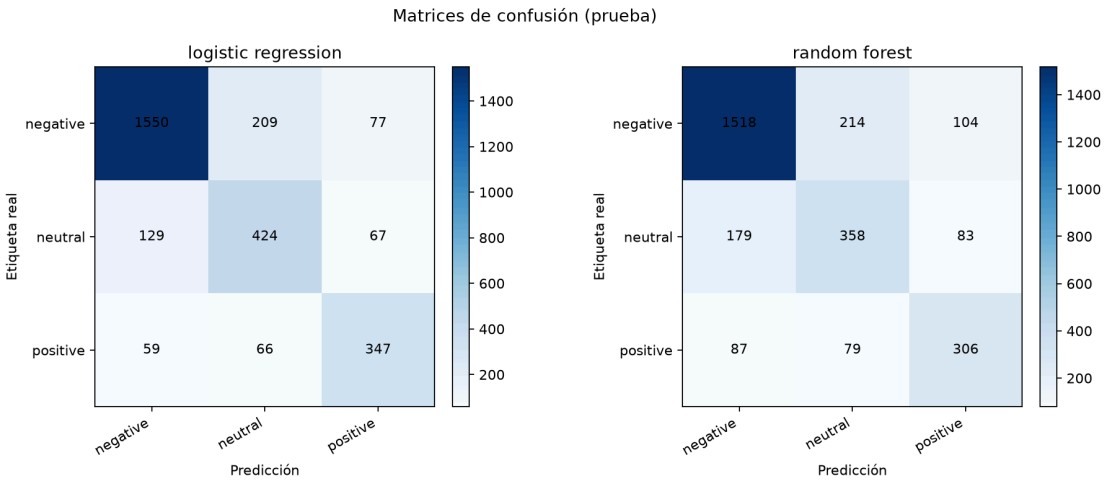
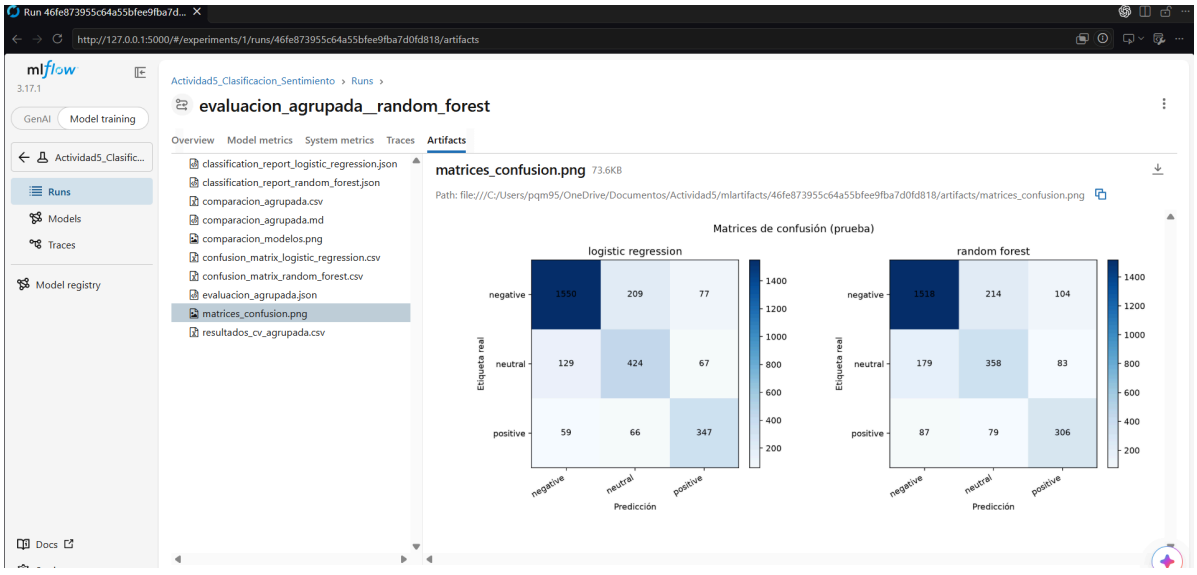


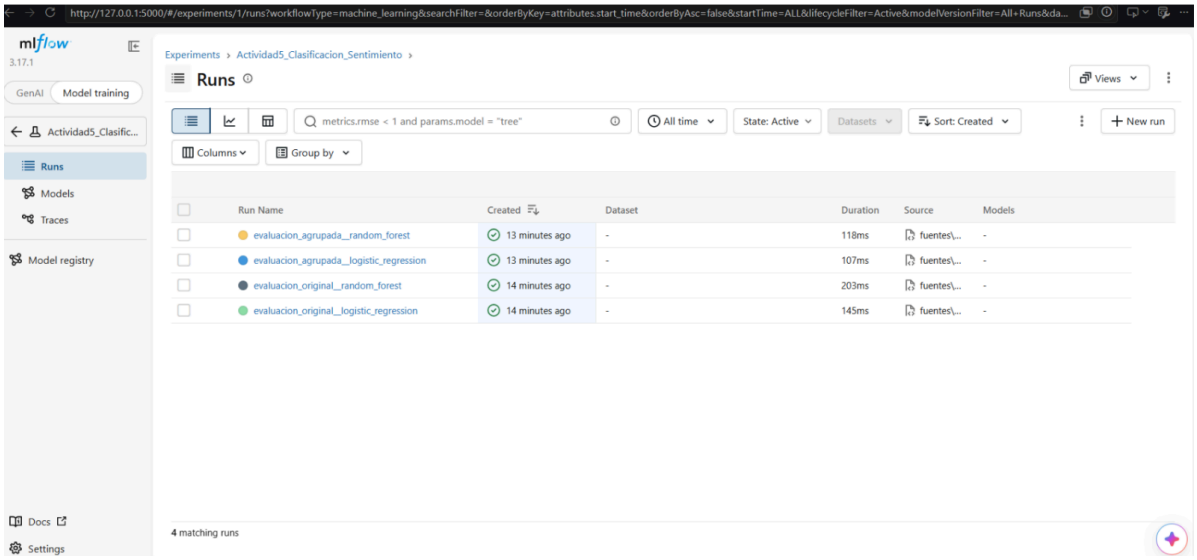
Figura 4. Matrices del escenario agrupado.

Seguimiento con MLflow

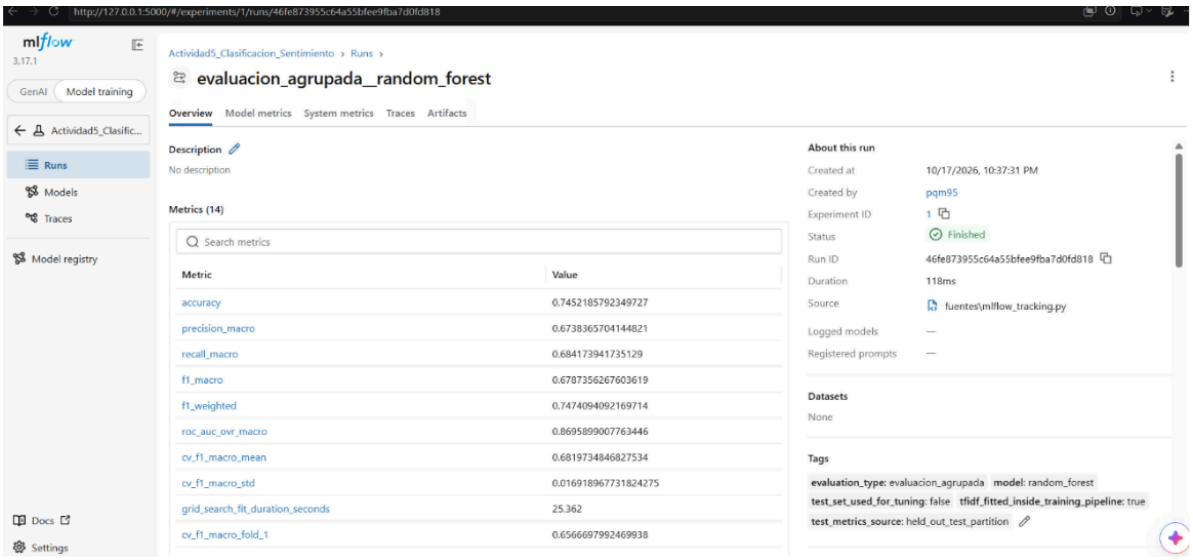
El experimento local Actividad 5_Clasificacion_Sentimiento contiene cuatro ejecuciones confirmadas en la interfaz (MLflow 3.17.1): logistic regression y random forest para evaluacion_original y evaluacion_agrupada. Los runs registran métricas, parámetros, versiones y artefactos; sus etiquetas marcan el escenario y especifican que la prueba no se usó en ajuste. Las ejecuciones registradas no guardan contenido de los comentarios ni serializan modelos. Las capturas insertadas son evidencia visual de la interfaz; la base SQLite y el almacenamiento interno de artefactos quedan fuera de este informe/Git.



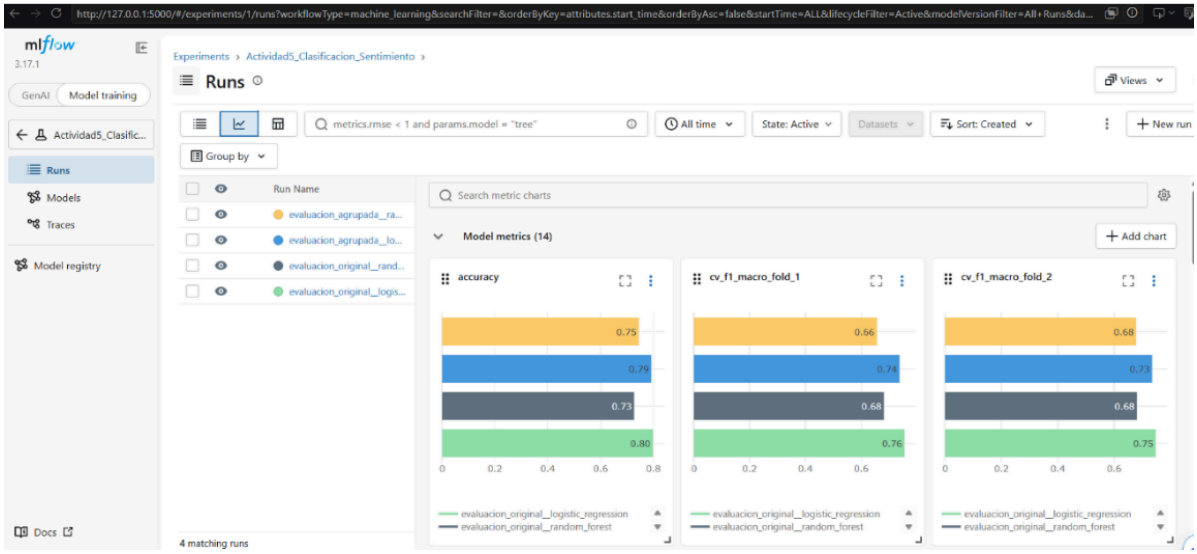
Evidencia MLflow 1



Evidencia MLflow 2



Evidencia MLflow 3



Evidencia MLflow 4

Pruebas y reproducibilidad

La suite unittest disponible reportó 7 pruebas OK en la última ejecución. pip check no reportó conflictos. Las dependencias se instalaron en el entorno virtual; el notebook complementario se validó como JSON y compilando estáticamente sus celdas, pero no se ejecutó integralmente porque no están instalados Jupyter ni ipykernel.

Para reproducir: crear .venv con Python 3.13, instalar requirements.txt, descargar Tweets.csv desde la URL de Kaggle y guardarlo en datos/datos_ini/, ejecutar fuentes/datos_prep.py, fuentes/train.py, fuentes/auditoria_fase3.py, fuentes/mlflow_tracking.py y después las pruebas con .venv/Scripts/python.exe -m unittest discover -s tests -v. Para consultar MLflow, ejecutar .venv/Scripts/mlflow.exe server --backend-store-uri sqlite:///mlflow.db --host 127.0.0.1 --port 5000 y abrir http://127.0.0.1:5000.

Reflexión sobre deuda técnica y MLOps

Durante el desarrollo de este proyecto se identificó que construir un modelo de clasificación de sentimientos no consiste únicamente en obtener buenas métricas, sino también en mantener un proceso ordenado, reproducible y fácil de actualizar. En este sentido, la deuda técnica puede aparecer cuando se dejan pendientes aspectos relacionados con la calidad de los datos, la documentación, las pruebas o la validación de los modelos.

En el proyecto, uno de los principales aspectos que se consideraro es la presencia de textos duplicados y de algunos registros con etiquetas de sentimiento contradictorias. Estas situaciones pueden influir en la evaluación del modelo y generar resultados que no representen completamente su capacidad de generalización. Por ello, se realizó una evaluación complementaria agrupando los textos idénticos, con el propósito de reducir el riesgo de que aparecieran tanto en los datos de entrenamiento como en los de

prueba. También se identificó como trabajo futuro la necesidad de evaluar el modelo con diferentes semillas y con datos externos.

La implementación de prácticas de MLOps permitió organizar mejor el proceso experimental. Mediante MLflow se registraron las ejecuciones de los modelos, sus parámetros y sus métricas, lo que facilita comparar resultados y consultar la evidencia de los experimentos. Además, se incorporaron pruebas para verificar componentes del proyecto y documenté el proceso de preparación de los datos y entrenamiento.

Estas prácticas ayudan a reducir la deuda técnica porque permiten identificar errores, dar seguimiento a los cambios y facilitar la reproducción de los experimentos. Sin embargo, el proyecto todavía tiene oportunidades de mejora: sería necesario establecer un mecanismo de monitoreo si el modelo se llevara a producción, revisar periódicamente la calidad de los datos y detectar

Conclusiones

En las ejecuciones que se realizaron, Regresión Logística obtuvo un F1 macro mayor que Random Forest en los dos protocolos de evaluación. Su F1 macro fue 0.7457 en la partición original y 0.7437 en la agrupada; la cercanía entre esos resultados es descriptiva y no prueba equivalencia ni significancia. La evaluación agrupada aporta una medición complementaria que elimina el solapamiento de textos idénticos. El flujo registra datos, resultados y evidencias de manera reproducible, sujeto a las limitaciones de la fuente y de los protocolos documentados.

Referencias

- Crowdflower. Twitter US Airline Sentiment. Kaggle, dataset y licencia CC BY-NC-SA 4.0. Consulta: 17 de octubre de 2026. https://www.kaggle.com/datasets/crowdflower/twitter-airline-sentiment/data
- Scikit-learn developers. Pipeline y composición de estimadores. https://scikit-learn.org/stable/modules/compose.html
- Scikit-learn developers. GridSearchCV. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html
- MLflow. Tracking experiments. https://mlflow.org/docs/latest/ml/tracking/